

AGENDA

3) Induktive Statistik

3.1) Induktive Statistik Einführung

3.1 INDUKTIVE STATISTIK EINFÜHRUNG

Das Ziel der induktiven (schließenden) Statistik besteht darin:

- Schlussfolgerungen von der Stichprobe auf die Grundgesamtheit zu ziehen.
- Aussagen können fehlerbehaftet sein,
- Um die Wahrscheinlichkeiten für Fehlentscheidungen einzugrenzen, werden die Methoden der Wahrscheinlichkeitstheorie angewandt.

Ziel: Aussage über ein Merkmal X (Zufallsvariable oder Zufallsvektor) sämtliche relevante Information über X steckt in der Verteilungsfunktion F von X , d.h. $F(x) = P(X \leq x)$, denn damit können sämtliche interessierenden Wahrscheinlichkeiten berechnet werden.

AGENDA

3) Induktive Statistik

3.2) Parameterschätzung

3.2 PARAMETERSCHÄTZUNG

Voraussetzung: Es sei $X \sim F_{\vartheta}$, $x_1, \dots, x_n$ eine Stichprobe und $X_1, \dots, X_n$ Stichprobenvariablen.

- Unter einer Statistik (Stichprobenfunktion) versteht man eine (messbare) Funktion, die nur von der Stichprobenvariablen $X_1, \dots, X_n$ abhängt
- Eine Statistik $g(X_1, \dots, X_n)$, deren Werte dazu verwendet werden, den Parameter ϑ zu schätzen, heißt eine Schätzfunktion oder kurz ein Schätzer für ϑ .
- $\hat{\vartheta} = g(x_1, \dots, x_n)$ heißt eine Schätzung für ϑ .

Bezeichnung: Häufig bezeichnet einen Schätzer bzw. eine Schätzung für ϑ mit $\hat{\vartheta}$.

Beispiele: Erwartungswert $\mu = E(X)$, ein Schätzer ist der **Mittelwert**:

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

3.2 PARAMETERSCHÄTZUNG

Beispiele: Schätzer für $Var(X)$ ist die empirische Varianz σ^2 :


$$\widehat{\sigma^2} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

- Verteilungsfunktion F , die obige Strategie liefert als Schätzer für F die **empirische Verteilungsfunktion $\hat{F}$** .
- Dichte bzw. Wahrscheinlichkeitsfunktion f Ein Schätzer für f ist das **Histogramm**.

Damit ist eine Verbindung zwischen den Kenngrößen für eine Datenmenge (**vgl. Deskriptive Statistik**) und den Kenngrößen für eine Verteilungsfunktion (**vgl. Wahrscheinlichkeitstheorie**) hergestellt. Die Kenngrößen für eine Datenmenge sind Schätzungen für die entsprechenden Kenngrößen der Verteilungsfunktion.


3.2 PARAMETERSCHÄTZUNG

Beispiel: Datensatz mtcars



```
271 # Laden des Datensatzes mtcars
272 data(mtcars)
273
274 # Visualisierung der Verteilung der Variable mpg
275 hist(mtcars$mpg, breaks = 10, main = "Verteilung der Variable mpg",
276      sub="Miles per gallon (or the metric equivalent kilometer per litre) ",
277      xlab = "mpg", col = "skyblue")
278
279 # Visualisierung der Dichte der Variable mpg
280 plot(density(mtcars$mpg), main = "Dichte der Variable mpg",
281      xlab = "mpg", ylab = "Dichte", col = "red", lwd = 2)
```

3.2 PARAMETERSCHÄTZUNG



bisher: Man erhält einen Schätzer, indem man bei den Kenngrößen für eine Verteilungsfunktion im diskreten Fall $P(X = x_i)$ bestimmt.

Notation: Häufig bezeichnet man den Schätzer mit Großbuchstaben und die Schätzung mit Kleinbuchstaben, z.B. $\bar{X}$ und $\bar{x}$.

jetzt: Wie kann man Schätzer für einen beliebigen Parameter erhalten?

AGENDA

3) Induktive Statistik

3.3) Hinführung zur Maximum-Likelihood-Methode

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

Nach Gauß 1821 und Fischer 1922

Beispiel:

Erfolg einer Behandlung $X \sim B(1, p)$ wobei $p = P(X = 1)$

$$X = \begin{cases} 1 & \text{falls Erfolg} \\ 0 & \text{kein Erfolg} \end{cases}$$

Eine Stichprobe vom Umfang $n = 4$ liefert die Beobachtungen 1, 1, 0, 1. Die Stichprobenvariablen $X_1, \dots, X_4$ seien unabhängig und $X_i \sim B(1, p)$ für $i = 1, \dots, 4$. Dann ist

$$\begin{aligned} & P(X_1 = 1, X_2 = 1, X_3 = 0, X_4 = 1) \\ &= P(X_1 = 1) \cdot P(X_2 = 1) \cdot P(X_3 = 0) \cdot P(X_4 = 1) \\ &= p^3(1 - p) = p^3 - p^4 =: L_p \end{aligned}$$

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

L_p ist gleich der Wahrscheinlichkeit, dass die Stichprobe 1, 1, 0, 1 auftritt, falls die Wahrscheinlichkeit für Erfolg gleich p ist.

Durch Maximierung von L_p für $p \in [0, 1]$ erhält man einen Schätzer für p .
Es ist

$$\frac{d}{dp} L_p = L'_p = 3p^2 - 4p^3 = 0,$$

Folglich ist $p = 0$ bzw. $p = 3/4$. Die Überprüfung der zweiten Ableitungen zeigt, dass das Maximum an der Stelle $3/4$ auftritt. Als Schätzung für p erhält man

$$\hat{p} = 0.75$$

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

Allgemein: Es seien $X_1, \dots, X_n$ unabhängige und identisch verteilte Zufallsvariable mit $X_i \sim F_\vartheta$, $\vartheta \in \Theta$. X_i besitze eine Dichte oder Wahrscheinlichkeitsfunktion f_ϑ

Die gemeinsame Dichte bzw. Wahrscheinlichkeitsfunktion f von $X_1, \dots, X_n$ ist gleich

$$\begin{aligned} P(X_1 = x_1 \cap X_2 = x_2 \dots \cap X_n = x_n) \\ = f(x_1, \dots, x_n; \vartheta) = \prod_{i=1}^n f_\vartheta(x_i) = L_\vartheta(\underline{x}) \end{aligned}$$

$L_\vartheta(x)$ heißt **Likelihood-Funktion**.

Ist X diskret, so gibt $L_\vartheta(x)$ die Wahrscheinlichkeit dafür an, dass X_1 den Wert x_1 , X_2 den Wert x_2 , ..., X_n den Wert x_n annimmt, falls der zugrunde liegende Parameter den Wert ϑ besitzt.

AGENDA

3) Induktive Statistik

3.3.1) Die Maximum-Likelihood-Methode

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

Durch Maximierung der Likelihood-Funktion L_{ϑ} über $\vartheta \in \Theta$ erhält man einen Schätzer für ϑ . Der resultierende Schätzer

$$\hat{\vartheta} = \arg \max_{\vartheta} L_{\vartheta}(x)$$

für ϑ heißt Maximum-Likelihood-Schätzer (ML-Schätzer). Vereinfacht gesprochen wird also als Schätzer für ϑ derjenige Wert genommen, für den die vorliegende Stichprobe am wahrscheinlichsten ist.

- Es muss kein Maximum existieren.
- Das Maximum muss nicht eindeutig bestimmt sein.
- Für die praktische Berechnung des Maximums ist es oft sinnvoller, statt L_{ϑ} die Funktion $\ln L_{\vartheta}$ zu maximieren. Wegen der strengen Monotonie der Logarithmusfunktion wird das Maximum an derselben Stelle angenommen.

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

$$\ln L_{\vartheta}(\underline{x}) = \ln \prod_{i=1}^n f_{\vartheta}(x_i) = \sum_{i=1}^n \ln f_{\vartheta}(x_i)$$

- Ist L_{ϑ} ein ML-Schätzer für ϑ , so ist $g(\widehat{\vartheta})$ ein ML-Schätzer für $g(\vartheta)$. Der ML-Schätzer ist unter geeigneten Anforderungen asymptotisch normalverteilt.

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

Vorgehensweise ML-Schätzung

- bei stetigen Variablen: Dichtefunktion der einzelnen Stichprobenvariablen aufstellen
- bei diskreten Variablen: Wahrscheinlichkeitsfunktion der einzelnen Stichprobenvariablen aufstellen
- Likelihood-Funktion bilden
- Log-Likelihood-Funktion berechnen
- Ableitung gleich Null setzen
- nach $\hat{\vartheta}$ auflösen
- überprüfen ob 2. Ableitung < 0 damit Maximum vorliegt

AGENDA

3) Induktive Statistik

3.3.2) Beispiele für die Maximum-Likelihood-Methode

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

Beispiel: ML-Schätzer für λ in Exponentialverteilung $Exp(\lambda)$ ist der ML-Schätzer gegeben durch $\hat{\lambda} = 1/\bar{X}$

Anwendung: Lebensdauer von Autobatterien in Jahren

.	6.9	1.3	10.8	10.3	0.4
.	6.5	4.2	21.8	4.0	2.7
.	3.0	41.3	0.2	15.3	15.3
.	5.5	2.1	2.5	5.8	9.1

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE


Beispiel: Lebensdauer von Autobatterien in Jahren

```
285 Lebensdauer <- c(6.9, 1.3, 10.8, 10.3, 0.4,  
286                 6.5, 4.2, 21.8, 4.0, 2.7,  
287                 3.0, 41.3, 0.2, 15.3, 15.3,  
288                 5.5, 2.1, 2.5, 5.8, 9.1);  
289  
290 hist(Lebensdauer, breaks = 10, freq = FALSE, ylim = c(0, 0.15),  
291      main = "Lebensdauer von Autobatterien in Jahren",  
292      xlab = "x", ylab = "f_hat(x) / f_12(x)",  
293      col=rgb(0,0,1,0.5) , lwd = 2.0);  
294  
295 lines(seq(from = 0.0, to = 50.0, length = 100),  
296       dexp(seq(from = 0.0, to = 50.0, length = 100),  
297           rate = 1 / mean(Lebensdauer)),  
298       col = "red", lwd = 2.0);
```

3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

Beispiel: Lebensdauer von Autobatterien in Jahren

Lebensdauer von Autobatterien in Jahren



3.3 DIE MAXIMUM-LIKELIHOOD-METHODE

Der Vergleich des Histogramms mit dem Schaubild der Exponentialverteilung zeigt, dass die Annahme einer exponentialverteilten Lebensdauer sinnvoll zu sein scheint. Der ML-Schätzer für λ ist gegeben durch

$$\hat{\lambda} = \frac{1}{8.45} = 0.11834$$

Somit ist ein Schätzer für die Wahrscheinlichkeit, dass die Lebensdauer einer Waschmaschine größer als 10 Jahre ist, gegeben durch

$$\begin{aligned} P(\widehat{X} > 10) &= \int_{10}^{\infty} 0.11834 \exp(-0.11834 x) dx \\ &= \exp(-0.11834 \times 10) \approx 0.306. \end{aligned}$$

AGENDA

3) Induktive Statistik

3.4) Hinführung zur Methode der kleinsten Fehlerquadrate

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Geht auf Gauß 1809 und Markov 1924 zurück (ordinary least squares (OLS))

Vorgehensweise:

- Zusammenhang zwischen beobachtetem Wert und unbekanntem
- Parameter der Grundgesamtheit bestimmen
- Zielfunktion aufstellen (Summe der quadrierten Abweichungen)
- Ableitung gleich Null setzen
- nach $\hat{\vartheta}$ auflösen
- überprüfen ob 2. Ableitung > 0 damit Minimum vorliegt

Im Gegensatz zur Maximum-Likelihood-Methode geht man bei der Methode der kleinsten Quadrate von keiner Verteilungsannahme aus.

AGENDA

3) Induktive Statistik

3.4.1) Beispiel zur Methode der kleinsten Fehlerquadrate

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Beispiel einfache lineare Regression:

Es wird ein funktionaler Zusammenhang zwischen einer **abhängigen Variablen (Regressand)** Y und einer **unabhängigen Variablen (Regressor)** X unterstellt. Beide Variablen seien metrisch skaliert. Bei der einfachen linearen Regression geht man von einer Stichprobe $(x_1, y_1), \dots, (x_n, y_n)$ aus, bei der die Stichprobenvariablen wie folgt zusammenhängen einfache lineare Regression

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad i = 1, \dots, n.$$

Die Störvariablen $\epsilon_1, \dots, \epsilon_n$ sind unkorreliert und es sei $E(\epsilon_i) = 0$ und $Var(\epsilon_i) = \sigma^2$ (Homoskedastizität) alle $i = 1, \dots, n$.


3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Beispiel mtcars Datensatz in R:

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160.0	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108.0	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360.0	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225.0	105	2.76	3.460	20.22	1	0	3	1
Duster 360	14.3	8	360.0	245	3.21	3.570	15.84	0	0	3	4
Merc 240D	24.4	4	146.7	62	3.69	3.190	20.00	1	0	4	2
Merc 230	22.8	4	140.8	95	3.92	3.150	22.90	1	0	4	2
Merc 280	19.2	6	167.6	123	3.92	3.440	18.30	1	0	4	4
Merc 280C	17.8	6	167.6	123	3.92	3.440	18.90	1	0	4	4
Merc 450SE	16.4	8	275.8	180	3.07	4.070	17.40	0	0	3	3
Merc 450SL	17.3	8	275.8	180	3.07	3.730	17.60	0	0	3	3
Merc 450SLC	15.2	8	275.8	180	3.07	3.780	18.00	0	0	3	3
Cadillac Fleetwood	10.4	8	472.0	205	2.93	5.250	17.98	0	0	3	4
Lincoln Continental	10.4	8	460.0	215	3.00	5.424	17.82	0	0	3	4
Chrysler Imperial	14.7	8	440.0	230	3.23	5.345	17.42	0	0	3	4
Fiat 128	32.4	4	78.7	66	4.08	2.200	19.47	1	1	4	1

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Lineare Einfachregression



3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Ziel: Schätzung der unbekannten Parameter β_0 und β_1 mittels einer Stichprobe $(x_1, y_1), \dots, (x_n, y_n)$

$$Q = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \longrightarrow \min_{\beta_0, \beta_1}$$

$$\frac{\partial Q(\beta_0, \beta_1)}{\partial \beta_0} = \sum_{i=1}^n 2 (y_i - \beta_0 - \beta_1 x_i) \cdot (-1) \stackrel{!}{=} 0,$$

$$\frac{\partial Q(\beta_0, \beta_1)}{\partial \beta_1} = \sum_{i=1}^n 2 (y_i - \beta_0 - \beta_1 x_i) \cdot (-x_i) \stackrel{!}{=} 0$$

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0, \quad \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i = 0.$$

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Damit erhält man die folgenden Schätzer für β_0 und β_1

$$\widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}, \quad \widehat{\beta}_1 = \frac{\tilde{s}_{yx}}{\tilde{s}_x^2}$$

mit

$$\tilde{s}_{yx} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \quad \tilde{s}_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

$$\frac{\partial^2 Q(\beta_0, \beta_1)}{\partial \beta_0^2} = 2n > 0, \quad \frac{\partial^2 Q(\beta_0, \beta_1)}{\partial \beta_1^2} = 2 \sum x_i^2 > 0$$

$$\frac{\partial^2 Q(\beta_0, \beta_1)}{\partial \beta_0 \partial \beta_1} = 2n\bar{x} \quad \text{und somit ist}$$

$$\det \left(\frac{\partial^2 Q(\beta_0, \beta_1)}{\partial \beta_i \partial \beta_j} \right)_{i,j=1,2} = 2n \left(\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \right) > 0$$

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Daraus ergibt sich die **Regressionsgerade** (Ausgleichsgerade) von Y auf X :

$$y = \widehat{\beta}_0 + \widehat{\beta}_1 x$$

durch umformung erhalten wir:

$$y = \bar{y} + \widehat{\beta}_1 (x - \bar{x}),$$

Beachte: Regressionsgerade geht durch die Punkte $(0, \beta_0)$ und $(\bar{x}, \bar{y})$.

AGENDA

3) Induktive Statistik

3.4.2) Beispiel mtcars Datensatz in R - Die Methode der kleinsten Fehlerquadrate

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Beispiel mtcars Datensatz in R:

```
306 reg <- lm(mpg ~ hp, data = mtcars)
307
308 predicted.mpg <- predict.lm(reg, interval = "prediction",
309                             level = 0.95);
310
311 # Ausgabe der Regressionskoeffizienten
312 summary(reg)
313
314 # Visualisierung der Regression
315 plot(mtcars$hp, mtcars$mpg, main = "Lineare Einfachregression",
316       xlab = "horse power", ylab = "miles per gallon", pch = 20, ylim=c(5,35), col = "skyblue")
317 abline(reg, col = "red", lwd = 2)
318 for (i in c(1 : length(mtcars$hp)))
319 {
320   lines(x = c(mtcars$hp[i], mtcars$hp[i]),
321         y = c(mtcars$mpg[i], predicted.mpg[i]),
322         col = rgb(1,0,1,0.2), lwd = 2.0);
323   lines(x = c(mtcars$hp[i], mtcars$hp[i] + (predicted.mpg[i] - mtcars$mpg[i])),
324         y = c(mtcars$mpg[i], mtcars$mpg[i]),
325         col = rgb(1,0,1,0.2), lwd = 2.0);
326   lines(x = c(mtcars$hp[i], mtcars$hp[i] + (predicted.mpg[i] - mtcars$mpg[i])),
327         y = c(predicted.mpg[i], predicted.mpg[i]),
328         col = rgb(1,0,1,0.2), lwd = 2.0);
329   lines(x = c(mtcars$hp[i] + (predicted.mpg[i] - mtcars$mpg[i]),
330               mtcars$hp[i] + (predicted.mpg[i] - mtcars$mpg[i])),
331         y = c(mtcars$mpg[i], predicted.mpg[i]),
332         col = rgb(1,0,1,0.2), lwd = 2.0);
333 }
```

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

```
311 # Ausgabe der Regressionskoeffizienten
312 summary(reg)
```

```
> summary(reg)
```

Call:

```
lm(formula = mpg ~ hp, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-5.7121	-2.1122	-0.8854	1.5819	8.2360

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	30.09886	1.63392	18.421	< 2e-16 ***
hp	-0.06823	0.01012	-6.742	1.79e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 3.863 on 30 degrees of freedom

Multiple R-squared: 0.6024, Adjusted R-squared: 0.5892

F-statistic: 45.46 on 1 and 30 DF, p-value: 1.788e-07

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Beispiel mtcars Datensatz in R:



3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Beispiel 2 mtcars Datensatz in R:

```
337 # Durchführen der linearen Einfachregression
338 reg2 <- lm(mpg ~ am, data = mtcars)
339
340 # Ausgabe der Regressionskoeffizienten
341 summary(reg2)
342
343 # Visualisierung der Regression
344 plot(mtcars$am, mtcars$mpg, main = "Lineare Einfachregression",
345      xlab = "transmission (automatic, gears)",
346      ylab = "miles per gallon", pch = 20, ylim=c(5,35), col = "darkgreen")
347 abline(reg2, col = "red", lwd = 2)
```

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Call:

```
lm(formula = mpg ~ am, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-9.3923	-3.0923	-0.2974	3.2439	9.5077

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	17.147	1.125	15.247	1.13e-15	***
am	7.245	1.764	4.106	0.000285	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.902 on 30 degrees of freedom


Multiple R-squared: 0.3598, Adjusted R-squared: 0.3385

F-statistic: 16.86 on 1 and 30 DF, p-value: 0.000285

3.4 DIE METHODE DER KLEINSTEN FEHLERQUADRATE

Beispiel 2 mtcars Datensatz in R:

Lineare Einfachregression



AGENDA

3) Induktive Statistik

3.5) Anforderungen an Schätzfunktionen

3.5 ANFORDERUNGEN AN SCHÄTZFUNKTIONEN

Frage: Wie gut ist ein Schätzer?

a) Erwartungstreue Schätzer

Ein Schätzer $\hat{\vartheta} = \hat{\vartheta}(X_1, \dots, X_n)$ heißt **erwartungstreu (unbiased)** für den Parameter ϑ , falls $E(\hat{\vartheta}) = \vartheta$ für alle $\vartheta \in \Theta$:

Ansonsten heißt der Schätzer **verzerrt**. Die Größe $\Delta = E(\hat{\vartheta}) - \vartheta$ heißt **Verzerrung (bias)**.

Beachte: Erwartungstreue (Unverzerrtheit) heißt, dass bei einer großen Anzahl der Stichproben der Durchschnittswert aller Schätzungen nahe dem wahren Parameter liegt.

3.5 ANFORDERUNGEN AN SCHÄTZFUNKTIONEN

Es seien $X_1, \dots, X_n$ Stichprobenvariablen mit $E(X_i) = \mu$ für $i = 1, \dots, n$. Dann ist $E(\bar{X}) = E(X_1) = \mu$. Somit ist $\bar{X}$ ein erwartungstreuer Schätzer für den Erwartungswert μ , aber auch X_1, X_2 und X_n .

Die Stichprobenvariablen $X_1, \dots, X_n$ seien unabhängig und identisch verteilt mit $E(X_i) = \mu$ und $Var(X_i) = \sigma^2$. Dann ist

$$E(\hat{\sigma}^2) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma^2.$$

Die empirische Varianz ist also kein erwartungstreuer Schätzer, allerdings

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

AGENDA

3) Induktive Statistik

3.5.1) Der mittlere quadratische Fehler

3.5.1 DER MITTLERE QUADRATISCHE FEHLER

Es ist wünschenswert, dass sich die Wahrscheinlichkeitsmasse des Schätzers möglichst dicht um den zu schätzenden Parameter konzentriert. Nach der Ungleichung von Tschebyscheff gilt für alle $\epsilon > 0$:

$$P(|\hat{\vartheta} - \vartheta| < \epsilon) \geq 1 - \frac{E((\hat{\vartheta} - \vartheta)^2)}{\epsilon^2}.$$

Dies zeigt, dass $P(|\hat{\vartheta} - \vartheta| < \epsilon)$ umso größer ist, je kleiner $E((\hat{\vartheta} - \vartheta)^2)$ ist. Die Größe heißt der mittlere quadratische Fehler (**mean square error (MSE)**) des Schätzers $\hat{\vartheta}$.

3.5.1 DER MITTLERE QUADRATISCHE FEHLER

Es ist

$$\begin{aligned}MSE(\hat{\vartheta}) &= E \left[(\hat{\vartheta} - E(\hat{\vartheta}) + E(\hat{\vartheta}) - \vartheta)^2 \right] \\&= Var(\hat{\vartheta}) + [E(\hat{\vartheta}) - \vartheta]^2 \\&= Var(\hat{\vartheta}) + Verzerrung^2,\end{aligned}$$

Somit ergibt sich der MSE als Summe aus Varianz und Quadrat des Bias.

Ist $\hat{\vartheta}$ ein erwartungstreuer Schätzer, so ist der MSE gleich $Var(\hat{\vartheta})$. Vergleicht man zwei Schätzer mittels des MSE-Kriteriums, so ist der Schätzer besser, der die kleinere mittlere quadratische Abweichung besitzt

3.5.1 DER MITTLERE QUADRATISCHE FEHLER

Die Stichprobenvariablen $X_1, \dots, X_n$ seien unabhängig und identisch verteilt mit $E(X_i) = \mu$ und $Var(X_i) = \sigma^2$. Dann ist $E(\bar{X}) = \mu$ und

$$MSE(\bar{X}) = Var(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n Var(X_i) = \frac{\sigma^2}{n},$$

Da

$$MSE(X_1) = \sigma^2 \geq MSE(\bar{X})$$

ist, ist $\bar{X}$ ein besserer Schätzer für μ als X_1 . Die Stichprobenvariablen $X_1, \dots, X_n$ seien unabhängig und normalverteilt mit $X_i \sim N(\mu, \sigma^2)$ für alle $i = 1, \dots, n$. Dann ist der MSE von $\hat{\sigma}^2$ kleiner gleich dem MSE von S^2 .

AGENDA

3) Induktive Statistik

3.5.2) Konsistente Schätzer

3.5.2 KONSISTENTE SCHÄTZER

jetzt: Anforderungen an das asymptotische Verhalten eines Schätzers. Ein Schätzer $\hat{\vartheta} = \hat{\vartheta}(x_1, \dots, x_n)$ heißt schwach konsistent (weakly consistent) für ϑ , falls für alle $\epsilon > 0$

$$P(|\hat{\vartheta} - \vartheta|) \rightarrow 0 \text{ für } n \rightarrow \infty$$

Eine Möglichkeit zum Nachweis der schwachen Konsistenz liefert die Tschebyscheff Ungleichung. Da

$$P(|\hat{\vartheta} - \vartheta|) \leq \frac{MSE}{\epsilon^2}$$

ist, ist es hinreichend zu zeigen, dass der MSE mit wachsendem n gegen Null strebt.

Beispiel: $\bar{X}$ ist ein schwach konsistenter Schätzer für μ , da

$$MSE(\bar{X}) = \frac{\sigma^2}{n} \rightarrow 0 \text{ für } n \rightarrow \infty:$$