

AGENDA

7) Tests für Zusammenhangsmaße

7.1) Normalverteilte Grundgesamtheit

7.1 NORMALVERTEILTE GRUNDGESAMTHEIT

Zu prüfen: Sind zwei Zufallsvariablen stochastisch unabhängig? Wir beschränken uns auf Zusammenhänge zwischen 2 Merkmalen X und Y .

Beispiele:

- Besteht ein Zusammenhang zwischen der Körpergröße eines Kindes (im Alter von 10 Jahren) und der des Vaters?
- Besteht ein Zusammenhang zwischen dem Einkommen und dem Alter

Testproblem

H_0 : X und Y unabhängig gegen H_1 : X und Y nicht unabhängig

Diese Frage soll mittels der (stochastisch) unabhängigen Stichprobenvariablen $(X_1, Y_1), \dots, (X_n, Y_n)$ beantwortet werden.

7.1 NORMALVERTEILTE GRUNDGESAMTHEIT

Es sei (X, Y) 2-dimensional normalverteilt mit

$$\begin{aligned} E(X) &= \mu_x, \text{Var}(X) = \sigma_x^2 \\ E(Y) &= \mu_y, \text{Var}(Y) = \sigma_y^2 \end{aligned}$$

Ferner sei

$$\rho = \text{Corr}(X, Y) := \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y} = \frac{E((X - \mu_x)(Y - \mu_y))}{\sigma_x \sigma_y}$$

Als Schätzer für ρ verwenden wir den Stichprobenkorrelationskoeffizienten nach Bravais und Pearson

$$\hat{\rho} = \frac{S_{XY}}{S_X S_Y}$$

7.1 NORMALVERTEILTE GRUNDGESAMTHEIT

Testproblem

$$\begin{aligned} H_0 : \rho &= 0 \text{ (d. h. } X \text{ und } Y \text{ unabhängig) gegen} \\ H_1 : \rho &\neq 0 \text{ (d. h. } X \text{ und } Y \text{ abhängig)} \end{aligned}$$

Teststatistik

$$T = \sqrt{n-2} \frac{\hat{\rho}}{\sqrt{1-\hat{\rho}^2}} \sim t_{n-2}$$

Testentscheidung

$$|T| > t_{n-2, 1-\alpha/2} \rightarrow H_0 \text{ ablehnen}$$

7.1 NORMALVERTEILTE GRUNDGESAMTHEIT

Beispiel: Korrelationstest für die beiden Cholesterindaten. Nehmen wir an, dass wir 2 verschieden Cholesterinmessungen von den selben Personen nur zu unterschiedlichen Zeitpunkten haben und wir wollen herausfinden ob diese von einander abhängen

```
463 Cholesterin.1 <- c(226, 255, 247, 211, 289, 190, 231, 276, 241, 210)
464 Cholesterin.2 <- c(220, 244, 243, 211, 299, 170, 210, 276, 252, 189)
465 var.test(Cholesterin.1, Cholesterin.2, ratio = 1, conf.level = 0.95)
481 cor.test(Cholesterin.1, Cholesterin.2, method=c("pearson"))
```

Pearson's product-moment correlation

```
data: Cholesterin.1 and Cholesterin.2
t = 11.521, df = 8, p-value = 2.923e-06
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.8790333 0.9933714
sample estimates:
      cor
0.9711593
```

AGENDA

7) Tests für Zusammenhangsmaße

7.2) Spearman Test

7.2 SPEARMAN TEST

Der Korrelationskoeffizient von Spearman ist eine Maßzahl für den monotonen Zusammenhang. Er ist für ordinale Daten geeignet. Es bezeichne $R(X_1), \dots, R(X_n)$ die Ränge von $X_1, \dots, X_n$ und $R(Y_1), \dots, R(Y_n)$ die Ränge von $Y_1, \dots, Y_n$.

Korrelationskoeffizient nach Spearman

$$R_{XY} = \frac{\sum_{i=1}^n (R(x_i) - \bar{R}) (R(y_i) - \bar{R})}{\sqrt{\sum_{i=1}^n (R(x_i) - \bar{R})^2 \sum_{i=1}^n (R(y_i) - \bar{R})^2}}$$

mit $\bar{R} = (n + 1)/2$.

7.2 SPEARMAN TEST

Testproblem

$H_0 : X$ und Y sind unabhängig gegen

$H_1 : X$ und Y sind monoton abhängig

Unter H_0 ist R_{XY} asymptotisch normalverteilt mit

$E(R_{XY}) = 0$ und $Var(R_{XY}) = 1/(n - 1)$.

Teststatistik

$$T = \sqrt{n - 1} R_{XY} \sim N$$

Testentscheidung

$$|T| > z_{1-\alpha/2} \rightarrow H_0 \text{ ablehnen}$$

7.2 SPEARMAN TEST

Beispiel: Niederschlag in Berlin und Brandenburg betrachtet als metrisches Merkmal

```
486 Niederschlag.Berlin <- c(120.5, 120.9, 120.3, 121.3, 120.4, 120.2)
487 Niederschlag.Brandenburg <- c(122.1, 121.5, 121.7, 121.1, 122.9, 121.8)
488 cor.test(Niederschlag.Berlin, Niederschlag.Brandenburg,
489           alternative = "two.sided", method = "pearson",
490           conf.level = 0.95)
```

Pearson's product-moment correlation

```
data: Niederschlag.Berlin and Niederschlag.Brandenburg
t = -1.5921, df = 4, p-value = 0.1866
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.9527851  0.3816766
sample estimates:
      cor
-0.6227992
```

7.2 SPEARMAN TEST

Beispiel: Niederschlag in Berlin und Brandenburg betrachtet als kategoriales Merkmal

```
492 Niederschlag.Berlin <- c(120.5, 120.9, 120.3, 121.3, 120.4, 120.2)
493 Niederschlag.Brandenburg <- c(122.1, 121.5, 121.7, 121.1, 122.9, 121.8)
494 cor.test(Niederschlag.Berlin, Niederschlag.Brandenburg,
495           alternative = "two.sided", method = "spearman",
496           conf.level = 0.95)
```

Spearman's rank correlation rho

```
data: Niederschlag.Berlin and Niederschlag.Brandenburg
S = 54, p-value = 0.2972
alternative hypothesis: true rho is not equal to 0
sample estimates:
      rho
-0.5428571
```

AGENDA

7) Tests für Zusammenhangsmaße

7.3) Chi-Quadrat-Test

7.3 CHI-QUADRAT-TEST

Chi-Quadrat (χ^2)-Koeffizient (Pearsonscher Kontingenzkoeffizient):

Es seien X und Y diskrete Merkmale mit nur endlich vielen Ausprägungen $a_1, \dots, a_k$ bzw. $b_1, \dots, b_l$.

Kontingenztafel der absoluten Häufigkeiten

X	Y			
	b_1	$\dots$	b_l	
a_1	n_{11}	$\dots$	n_{1l}	$n_{1\cdot}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
a_k	n_{k1}	$\dots$	n_{kl}	$n_{k\cdot}$
	$n_{\cdot 1}$	$\dots$	$n_{\cdot l}$	n

Dabei sei $n_{i\cdot} = \sum_{v=1}^l n_{iv}$ und $n_{\cdot j} = \sum_{v=1}^k n_{vj}$

7.3 CHI-QUADRAT-TEST

Testproblem

H_0 : X und Y sind unabhängig gegen
 H_1 : X und Y sind nicht unabhängig

Prüfgröße

$$T = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - n_{i.}n_{.j}/n)^2}{n_{i.} n_{.j}/n}$$

$$\lim_{n \rightarrow \infty} P(T \leq y) = \chi_{(l-1)(k-1)}^2(y)$$

Testentscheidung

$$T > \chi_{(l-1)(k-1);1-\alpha} \rightarrow H_0 \text{ ablehnen}$$

7.3 CHI-QUADRAT-TEST

Beispiel: Beispiel mtcars mpg und am

	V1	V2	V3	V4	V5	V6	V7	V8	V9	V10	V11	V12	V13	V14	V15	V16
mtcars.mpg	21	21	22.8	21.4	18.7	18.1	14.3	24.4	22.8	19.2	17.8	16.4	17.3	15.2	10.4	10.4
mtcars.am	1	1	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

```
500 View(t(data.frame(mtcars$mpg, mtcars$am)))
501
502 chisq.test(mtcars$mpg, mtcars$am)
```

Pearson's Chi-squared test

data: mtcars\$mpg and mtcars\$am

X-squared = 27.854, df = 24, p-value = 0.2662

Warnmeldung:

In `chisq.test(mtcars$mpg, mtcars$am)` :

Chi-Quadrat-Approximation kann inkorrekt sein