

AGENDA

8) Lineare Regression

8.1) Einfache Lineare Regression

8.1 EINFACHE LINEARE REGRESSION

Ziel: Aussage über den linearen Zusammenhang zwischen einer abhängigen Variablen (Regressand) Y und gewissen unabhängigen Variablen (Faktoren, Regressoren) $X_1, \dots, X_p$

Mittels einer Stichprobe $(x_{11}, \dots, x_{1p}; y_1), \dots, (x_{n1}, \dots, x_{np}; y_n)$ sollen Aussagen über das Modell gemacht werden.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad i = 1, \dots, n.$$

Die Störvariablen $\epsilon_1, \dots, \epsilon_n$ sind unkorreliert und es sei $E(\epsilon_i) = 0$ und $\text{Var}(\epsilon_i) = \sigma^2$ (Homoskedastizität) alle $i = 1, \dots, n$. Ferner sei der Regressor deterministisch.

8.1 EINFACHE LINEARE REGRESSION

Die Regressionsgerade ist gegeben durch

$$Y = Y(X) = \widehat{\beta}_0 + \widehat{\beta}_1 x = \bar{Y} + \widehat{\beta}_1 (x - \bar{x}).$$

Um Tests für die Parameter einer linearen Regression herleiten zu können, braucht man stärkere Anforderungen an die Fehlervariablen $\{\epsilon_t\}$.

- $E(\epsilon_i) = 0$, für alle i ,
- $Var(\epsilon_i) = \sigma_i^2$, für alle i ,
- $Cov(\epsilon_i, \epsilon_j) = 0$, für alle $i, j, i \neq j$;
- $\epsilon_i \sim N(0, \sigma_\epsilon^2)$, für alle i ,

8.1 EINFACHE LINEARE REGRESSION

Testproblem

$$H_0 : \beta_0 = 0 \text{ gegen } H_1 : \beta_0 \neq 0$$

Teststatistik

$$T = \frac{\widehat{\beta}_0}{\hat{\sigma} \sqrt{1 + \bar{x}^2 / \widetilde{s}_x^2}} \sqrt{n} \sim t_{n-2}$$

Testentscheidung

$$|T| > t_{n-2; 1-\alpha/2} \rightarrow H_0 \text{ ablehnen}$$

8.1 EINFACHE LINEARE REGRESSION

Testproblem

$$H_0 : \beta_1 = 0 \text{ gegen } H_1 : \beta_1 \neq 0$$

Teststatistik

$$T_1 = \frac{\widehat{\beta}_1}{\widehat{\sigma}} \sqrt{n} \widetilde{s}_x \sim t_{n-2}$$

Testentscheidung

$$|T_1| > t_{n-2; 1-\alpha/2} \rightarrow H_0 \text{ ablehnen}$$

Dieser Test wird in der Literatur auch als **partieller t-Test** bezeichnet.

8.1 EINFACHE LINEARE REGRESSION

Beispiel: mtcars einfache lineare Regression

```
508 # Durchführen der linearen Einfachregression mit mpg und wt(weight)
509 reg_wt <- lm(mpg ~ wt, data = mtcars)
510
511 # Ausgabe der Regressionskoeffizienten
512 summary(reg_wt)
```

```
> summary(reg_wt)
```

Call:

```
lm(formula = mpg ~ wt, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.5432	-2.3647	-0.1252	1.4096	6.8727

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	37.2851	1.8776	19.858	< 2e-16 ***
wt	-5.3445	0.5591	-9.559	1.29e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.046 on 30 degrees of freedom


Multiple R-squared: 0.7528, Adjusted R-squared: 0.7446

F-statistic: 91.38 on 1 and 30 DF, p-value: 1.294e-10

8.1 EINFACHE LINEARE REGRESSION

Beispiel: mtcars einfache lineare Regression

Lineare Einfachregression



AGENDA

8) Lineare Regression

8.2) Prognose

8.2 PROGNOSE

Prognose (Vorhersage) für Y_T

$$\hat{Y}_T = \hat{\beta}_0 + \hat{\beta}_1 x_T$$

Eigenschaften des Prognosefehlers:

- $E(\hat{\epsilon}_T) = 0, \text{Var}(\hat{\epsilon}_T) = \sigma^2 \left(1 + \frac{1}{n} \left[1 + \frac{(x_T - \bar{x})^2}{\tilde{s}_x^2} \right] \right)$

Prognoseintervall für Y_T zum Niveau $1 - \alpha$:

$$KI = \left[\hat{Y}_T - \hat{\sigma} \sqrt{1 + \frac{1}{n} \left(1 + \frac{(x_T - \bar{x})^2}{\tilde{s}_x^2} \right)} t_{n-2; 1-\alpha/2}; \right. \\ \left. \hat{Y}_T + \hat{\sigma} \sqrt{1 + \frac{1}{n} \left(1 + \frac{(x_T - \bar{x})^2}{\tilde{s}_x^2} \right)} t_{n-2; 1-\alpha/2} \right]$$

8.2 PROGNOSE


Beispiel: mtcars einfache lineare Regression aus dem Kapitel 8.1

```
530 # Visualisierung
531 plot(mtcars$wt, mtcars$mpg, main = "Linear Regression und Prognose",
532      xlab = "Gewicht", ylab = "mpg")
533 abline(model, col = "red") # Regression-Linie hinzufügen
534 lines(newdata$wt, pred, col = "blue", lty= 2, lwd=2)
535 lines(newdata$wt, predict(model,newdata, interval = "prediction")[, "lwr"],
536      col = "dark green", type = "l", lwd = 2.0, lty = 2);
537 lines(newdata$wt, predict(model,newdata, interval = "prediction")[, "upr"],
538      col = "dark green", type = "l", lwd = 2.0, lty = 2);
539 # Vorhersage hinzufügen
540 legend("topright", legend = c("Regression", "Prognose"),
541      col = c("red", "blue"), lty = c(1,2), lwd=c(1,2), cex=0.9)
```

8.2 PROGNOSE

Beispiel:

Linear Regression und Prognose



AGENDA

8) Lineare Regression

8.3) Multiple Regression

8.3 MULTIPLE REGRESSION

Frage: Lässt sich das Verhalten einer abhängigen Variablen Y durch k linear zusammenhängende unabhängige Variable $X_1, \dots, X_p$ sinnvoll erklären?

Multiple lineare Regression

$$Y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \epsilon_i, \quad i = 1, \dots, n$$

Annahmen:

- $E(\epsilon_i) = 0$, bei stochastischen Regressoren $E(\epsilon_i | x_{ij}) = 0$ für alle i ,
- $Var(\epsilon_i) = \sigma^2$, für alle i , (Homoskedastizität)
- $Cov(\epsilon_i, \epsilon_j) = 0$, für alle $i, j, i \neq j$; (Unkorreliertheit)
- $n \geq p + 1$

8.3 MULTIPLE REGRESSION

Beispiel: mtcars multiple lineare Regression

```
546 # Multiple Linear Regression
547 model <- lm(mpg ~ wt + am + hp, data = mtcars)
548 # mpg gegenüber Gewicht + Motor + Pferdestärke
549 summary(model) # Zusammenfassung des Modells
```

Call:

```
lm(formula = mpg ~ wt + am + hp, data = mtcars)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-3.4221	-1.7924	-0.3788	1.2249	5.5317

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	34.002875	2.642659	12.867	2.82e-13	***
wt	-2.878575	0.904971	-3.181	0.003574	**
am	2.083710	1.376420	1.514	0.141268	
hp	-0.037479	0.009605	-3.902	0.000546	***

8.3 MULTIPLE REGRESSION

Voraussetzungen: $\mathbf{X}$ bekannt, $n \geq p + 1$, $\epsilon_i \sim N(0, \sigma^2)$ und unabhängig.

Partieller t-Test das Testproblem

$$H_0 : \beta_i = \beta^* \text{ gegen } H_1 : \beta_i \neq \beta^*$$

wobei β^* bekannt sei und $i \in \{0, \dots, p\}$

Teststatistik

$$T_i = \frac{\hat{\beta}_i - \beta^*}{\hat{\sigma} \sqrt{b_{ii}}} \sim t_{n-p-1}$$

Testentscheidung

$$|T_1| > t_{n-p-1; 1-\alpha/2} \rightarrow H_0 \text{ ablehnen}$$

8.3 MULTIPLE REGRESSION

Beispiel: mtcars multiple lineare Regression

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	34.002875	2.642659	12.867	2.82e-13	***
wt	-2.878575	0.904971	-3.181	0.003574	**
am	2.083710	1.376420	1.514	0.141268	
hp	-0.037479	0.009605	-3.902	0.000546	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.538 on 28 degrees of freedom

Multiple R-squared: 0.8399, Adjusted R-squared: 0.8227

F-statistic: 48.96 on 3 and 28 DF, p-value: 2.908e-11

8.3 MULTIPLE REGRESSION

Wie gut beschreibt ein ausgewähltes Regressionsmodell die Daten?

Ziel: Maß für die Güte der Modellanpassung

Bestimmtheitsmaß R^2

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

Gesamtstreuung = Reststreuung + erklärte Streuung

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

8.3 MULTIPLE REGRESSION

Eigenschaften des Bestimmtheitsmaß R^2

- $0 \leq R^2 \leq 1$
- $R^2 = 1 \rightarrow Y_i = \hat{Y}_i$, für $i = 1, \dots, n$
- $R^2 = 0 \rightarrow \bar{Y}_i = \hat{Y}_i$, für $i = 1, \dots, n$

Je näher R^2 bei 1, desto besser beschreibt das ausgewählte Modell die Daten.

Beispiel: Mtcars mit $mpg = Y_i$ und am, wt und hp als x_{ij}

Residual standard error: 2.538 on 28 degrees of freedom

Multiple R-squared: 0.8399, Adjusted R-squared: 0.8227

F-statistic: 48.96 on 3 and 28 DF, p-value: 2.908e-11



8.3 MULTIPLE REGRESSION

Testproblem (overall F-Test)

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \text{ gegen } H_1 : \exists j \text{ mit } \beta_j \neq 0$$

Teststatistik

$$F = \frac{n-p-1}{p} \frac{R^2}{1-R^2} = \frac{n-p-1}{p} \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \sim F_{p,n-p-1}$$

Testentscheidung

$$F > F_{p,n-p-1;1-\alpha} \rightarrow H_0 \text{ ablehnen}$$

AGENDA

8) Lineare Regression

8.4) Modellselektion

8.4 MODELLSELEKTION

Angepasstes Bestimmtheitsmaß $\bar{R}^2$

$$\bar{R}(k)^2 = 1 - \frac{\hat{\sigma}(k)^2}{\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{\frac{1}{n-k-1} \sum (\hat{Y}_i - Y_i)^2}{\frac{1}{n-1} \sum (Y_i - \bar{Y})^2} = 1 - \frac{n-1}{n-k-1} (1 - R(k)^2)$$

k bezeichnet die unterstellte Modellordnung. Zudem ist

$$-\frac{k}{n-k-1} \leq \bar{R}(k)^2 \leq 1$$

Das Ziel ist ein Schätzer für die unbekannte Modellordnung. Dabei kann $\bar{R}(k)^2$ maximiert werden. Die Maximierung von $\bar{R}^2$ ist äquivalent zur Minimierung von σ^2 . Der Schätzer ist nicht allzu gut.

8.4 MODELLSELEKTION

Akaike (ca. 1970), Schwarz (Ende 1970),... Informationskriterium. Man geht von der Zusatzanforderung $\epsilon_t \sim N(0, \sigma^2)$ aus.

$$BIC(k) = \ln \hat{\sigma}(k)^2 + k \frac{\ln n}{n},$$

$$AIC(k) = \ln \hat{\sigma}(k)^2 + k \frac{2}{n}.$$

Wähle das Modell mit minimalem BIC für $0 \leq k \leq P$. Manchmal schreibt man anstelle von BIC auch SBC (Schwarzsches Bayes-Kriterium).

Es wird das Informationskriterium für alle Möglichkeiten der Regressoren berechnet. Das beste Modell liefert diejenige Regressorenauswahl, für die das Informationskriterium am kleinsten ist.

8.4 MODELLSELEKTION

Beispiel:

```
555 # Overfitting als Problem
556 # Multiple Linear Regression
557 model_4 <- lm(mpg ~ ., data = mtcars)
558 summary(model_4) # Zusammenfassung d
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	12.30337	18.71788	0.657	0.5181
cyl	-0.11144	1.04502	-0.107	0.9161
displ	0.01334	0.01786	0.747	0.4635
hp	-0.02148	0.02177	-0.987	0.3350
drat	0.78711	1.63537	0.481	0.6353
wt	-3.71530	1.89441	-1.961	0.0633 .
qsec	0.82104	0.73084	1.123	0.2739
vs	0.31776	2.10451	0.151	0.8814
am	2.52023	2.05665	1.225	0.2340
gear	0.65541	1.49326	0.439	0.6652
carb	-0.19942	0.82875	-0.241	0.8122

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.65 on 21 degrees of freedom

Multiple R-squared: 0.869, Adjusted R-squared: 0.8066

F-statistic: 13.93 on 10 and 21 DF, p-value: 3.793e-07

8.4 MODELLSELEKTION

Beispiel: step function zur Optimierung des Modells

```
562 best_model <- step(model_4, scale = 0,  
563     direction = "backward",  
564     trace = 1);  
565  
566 summary(best_model)
```

Call:
lm(formula = mpg ~ wt + qsec + am, data = mtcars)

Residuals:

Min	1Q	Median	3Q	Max
-3.4811	-1.5555	-0.7257	1.4110	4.6610

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	9.6178	6.9596	1.382	0.177915
wt	-3.9165	0.7112	-5.507	6.95e-06 ***
qsec	1.2259	0.2887	4.247	0.000216 ***
am	2.9358	1.4109	2.081	0.046716 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.459 on 28 degrees of freedom

Multiple R-squared: 0.8497, Adjusted R-squared: 0.8336

F-statistic: 52.75 on 3 and 28 DF, p-value: 1.21e-11